






غلط است زیرا اگر تمام مسیرها بین D ، A را در تقدیر نکنیم:



با هم تمام مسیرها مستقل باشند در صورت که همان $A \leftarrow D, A \leftarrow C$ داشته باشد.




غلط است زیرا اگر تمام مسیرها بین B ، A را در تقدیر نکنیم:



با هم تمام مسیرها مستقل باشند در صورت که همان $E \leftarrow A$ داشته باشد.

است زیرا $A \leftarrow E | B$

است زیرا اگر تمام مسیرها بین C, B و A را در تقدیر نکنیم داریم:



مسیرها مستقل هستند: $C, B \leftarrow A$ در صورت که A مسیرهای سُلْنَان

است $B \leftarrow C | A$


غلط است. هاتچ برتر C است باز هم تعداد E دیگر سُلْنَان است: $B \leftarrow E \leftarrow C$

active path \subseteq جمله \subseteq active path \subseteq داریم بین C, B ، دامنه آن را \subseteq می‌نیزیم


بررسی محدود آخر نمی‌شود (البته $B \leftarrow C$ محدود آخوند است) $B \leftarrow C | A, E$ است زیرا

Q


دليل فD G. مفهوميّاتی دلیل : DLF/E




active path



Inactive path



active path



→ Inactive path

دليل فD G. دليل active مفهوميّاتی دليل : DLF/E ← داسنون

د) markov net، جمعت ناگیر و استقلال‌ها به این صورت اینکه آنگرچه مسیر global markov property دارد نهاده باشیم، آن دلود مستقل آنکه باید دنباله ~~باشیم~~ unobserved کنند می‌شود.

در bayes net، جمعت در می‌داند استقلال‌ها با توجه به d -separation می‌شوند، وقتی که تمام مسیرهای بین دلود نهاده آن دلود مستقل آنند.

حالا از آنجایی که اسلکت دوگراف یکسان است، در markov net، در هرجا بخواهیم استقلال داشت باشیم باید در ~~د~~ bayes net هر استقلال طبقه باشیم و برعکس.

حالا نزدیکی که مسیر بینشان نیست که مشکلی ایجاد نمی‌کند و استقلال مترکی شان یکسان است در هر دو شبکه bayes، markov، bayesnet، مسئله نزدیکی مستقل شده است و مسیر داشته.

آنکه دلود مستقله هر دویل باشد و باستثنی دلود در هر دو اینظاهی است و مشکلی ایجاد نمی‌شود.

حالا هر زنگی در دست این مسیر بگذیرید، آنکه آنرا بینشید دلود سروچه مسیر به سفرط این دلود markov مستقل آنند. (به عبارتی که path صاف بین دلود را بگذیرد از هر کدام به تعدادی را می‌شوند، این دلود مستقل می‌شوند به سفرط دلود آن دلود هار و سعی در ~~در~~ markovnet)

پس در bayesnet هر باید باید دلود استقلال ~~با~~ اتفاق بینند، از آنجایی که ما هر رهی از دلود هار دست می‌توانیم برداریم و observe کنیم باید ~~با~~ V -structure bayesnet نهاده باشیم (Q).

چون در این حالت؟ observe شدن دلود active ~~با~~ $triple$ تشكیل می‌کند و باستثنی ایجاد می‌کند. سعی تمام مسیرهای هابصورت $O \rightarrow O, O \rightarrow O, O \rightarrow O$ باید باشد.

۳) جواب ~~با~~، برای هر مسیر X ، X Parent آن باید تمام همسایه‌هایش باشد. زیرا در markov بمحض

دلود به $\{O\}$ همسایه‌هایش از سایر دلودها مستقل است و در bayes، هر دلود به سفرط

از سایر نواده ها مستقل است. همین G نباید دور طسته باشد، زیرا آن دیگر

Markov / bayes ب دور حبس طور می تواند به شکل markov تبدیل شود

همین سطر هار احتالی در G بوده با ترتیب هار سطحی می خواهد H همچنانی داشته باشد، این همچنانی تفسیر می کند که داسکی هار محلی در دو صفتی یکسان است.

-۳ با در تطابق کردن $h_i \in H$, $v_i \in V$ بیان می شود

$$P(H_k = h_k | V) = \frac{P(H_k = h_k, V)}{P(V)} = \frac{P(H_k = h_k, V)}{\sum_{h_k} P(H_k = h_k, V)} = \frac{P(H_k = h_k, V)}{P(H_k = 0, V) + P(H_k = 1, V)}$$

که در فرمول داده شده عبارت صورت و دو عبارت مخرج به ترتیب در مقادیر H_k تعداد طرفینه h_k , V قرار دارد
است \rightarrow و بعیو/ متغیر با هر یک می میگویند یعنی در تابع

$$P(H_k = h_k | V) = \frac{\exp(\alpha_k h_k + h_k \sum_i w_{ki} v_i) \times t}{\exp(0 \times t) + \exp(\alpha_k + \sum_i w_{ki} v_i) \times t}$$

متغیر معرفی شده
هر سطر عبارت است

$$\Rightarrow P(H_k = h_k | V) = \frac{\exp(\alpha_k h_k + h_k \sum_i w_{ki} v_i)}{1 + \exp(\alpha_k + \sum_i w_{ki} v_i)}$$

$\sigma(-)$

$$\Rightarrow P(h_j = 1 | V) = \frac{\exp(\alpha_j + \sum_i w_{ji} v_i)}{1 + \exp(\alpha_j + \sum_i w_{ji} v_i)} = \frac{1}{1 + \exp(-(\alpha_j + \sum_i w_{ji} v_i))}$$

$$\Rightarrow P(h_j = 1 | V) = \sigma(\alpha_j + \sum_i w_{ji} v_i),$$

$$P(h_j = 0 | V) = 1 - \sigma(\alpha_j + \sum_i w_{ji} v_i)$$

با رسمیت دیدن از استقلال هم در ادامه این را بدل را نشان می دهیم
حال باید نشان دهیم $P(H | V) = \prod_j P(H_j | V)$ طبق اصل اینها داشته باشند اگر مسیر

بن دو متغیر داشته باشند آن دو دامنه اند H_j اگر ناشناخته باشند مستقل اند در سطح دو هر

وضعیت داشته، حال هر H_i به تمام V_i ها متعلق است \leftarrow اگر تمام V_i ها observed باشند

H_i جمله تمام حسابی های V_i ها هستند، بر قرآن V از سایری مستقل است، به عبارت داشته باشند

هر چند بر قرآن هایی از سایری مستقل است \leftarrow هر چند H_i بر قرآن V ، از تمام V_i ها داشته باشند

باشد مستقل اند

$$P(H|V) = P(H_1|V) \underbrace{P(H_2|H_1, V)}_{P(H_2|V)} \cdots \underbrace{P(H_n|H_1, H_2, \dots, H_{n-1}, V)}_{P(H_n|V)}$$

$$\Rightarrow P(H|V) = \prod_j P(H_j|V)$$

حالياً ينظر H_j بحسب

$$P(H_j|V) = \sigma(\alpha_j + \sum_i w_{ji} v_i)^{h_j} \left(1 - \sigma(\alpha_j + \sum_i w_{ji} v_i)\right)^{1-h_j}$$

$$\Rightarrow P(H|V) = \prod_j \sigma(\alpha_j + \sum_i w_{ji} v_i)^{h_j} \left(1 - \sigma(\alpha_j + \sum_i w_{ji} v_i)\right)^{1-h_j}$$

ب) دوباره لازم است این ماتریس را با استفاده از chain rule محاسبه کنیم،

$$P(V|H) = P(v_1, \dots, v_m | H) = P(v_1|H) P(v_2|v_1, H) \cdots P(v_m|v_1, \dots, v_{m-1}, H)$$

که به صورت مسأله ایستاده تمام v_i ها observe باشند، هر v_k به کل تمام H_i ها از پرداخت
مسئله است دقیقاً مطابق توصیهای بعض الفی و مقطع اینبار جای v_i و H_i عوض نموده است.

$$\Rightarrow P(V|H) = \prod_j P(v_j|H)$$

$$P(v_j=v_j|H) = \frac{P(v_j=v_j, H)}{P(H)} = \frac{P(v_j=v_j, H)}{P(v_j=1, H) + P(v_j=0, H)}$$

به صورت مسأله بالف صورت رسمیت مسئله محاسبه کردیم،

$$\Rightarrow P(v_i=v_j|H) = \frac{\exp(b_j v_j + v_j \sum_i w_{ij} h_i) \times t}{\exp(0) \times t + \exp(b_j + \sum_i w_{ij} h_i) \times t} = \frac{\exp(b_j v_j + v_j \sum_i w_{ij} h_i)}{1 + \exp(b_j + \sum_i w_{ij} h_i)}$$

$$\Rightarrow P(V_j=1 | H) = \frac{\exp(b_j + \sum_i w_{ij} h_i)}{1 + \exp(b_j + \sum_i w_{ij} h_i)} = \frac{1}{1 + \exp(-(b_j + \sum_i w_{ij} h_i))} \rightarrow \sigma(-)$$

$$\Rightarrow P(V_j=1 | H) = \sigma(b_j + \sum_i w_{ij} h_i)$$

$$P(V_j=0 | H) = 1 - \sigma(b_j + \sum_i w_{ij} h_i)$$

$$P(V_j | H) = \sigma(b_j + \sum_i w_{ij} h_i)^{V_j} (1 - \sigma(b_j + \sum_i w_{ij} h_i))^{1-V_j}$$

$$\Rightarrow P(V | H) = \prod_j \sigma(b_j + \sum_i w_{ij} h_i)^{V_j} (1 - \sigma(b_j + \sum_i w_{ij} h_i))^{1-V_j}$$

$$P(V | H) = \frac{P(V, H)}{P(H)} \Rightarrow P(H) = \frac{P(V, H)}{P(V | H)}$$

$$\Rightarrow P(H) = \frac{\frac{1}{Z} \exp \left(\sum_i \alpha_i h_i + \sum_j b_j V_j + \sum_{i,j} w_{ij} h_i V_j \right)}{\prod_j \sigma(b_j + \sum_i w_{ij} h_i)^{V_j} (1 - \sigma(b_j + \sum_i w_{ij} h_i))^{1-V_j}}$$

راه دلخواه

می توانیم تحریر کنیم.

$$E(V, h) = - \sum_i \alpha_i h_i - \sum_j b_j V_j - \sum_{i,j} w_{ij} h_i V_j$$

$$\Rightarrow E(V, h) = -(\alpha^T h + b^T V + h^T W V)$$

$$\Rightarrow P(V, h) = \frac{1}{Z} e^{-E(V, h)}$$

$$P(h) = \frac{1}{Z} \sum_{\{V\}} e^{-E(V, h)}$$

در هر دو حالت نمای توانی توزیع $P(H)$ را ریخته کنیم. دلیل مدلک در نیز داریم که نمای توانی $P(H)$ را ریخته کنیم.

$$P(H) = \sum_j P(v_j, H)$$

در هر سری مدلکی v_i را دریاب و به لذت آن سی v_i . H ها مستغلی می‌شوند در فاعل بسی از صفات کردن این $\sum_j H_j$ ها بی‌سری ارتباط با هر گزند مستغل می‌شوند. بنابراین جمع این مقادیر مصنوعی بیان v_i ها، حالا جوں مستغل می‌شوند با هر ارتباط ای داشت نمای توانی $P(H)$ را در H_i ها بیکنیم.

سُود بسته هر H_i بی v_i از صفت w_i مرتبط است، وقتی جمع می‌بندیم روی تمام حالات $\sum_j P(H)$ را بدست آوری w_i ها hidden units مرتبطی می‌شوند جوں احتمال joint به تمام v_i ها configuration پستی کاره.

(بررسی) استقلال حاکمیتی که در مراکف حضرت، در توزیع H حضرت در معمولاً در RBN این تعاق نمای انتقام استقلال شرطی در مکاف باندیشید توزیع بناسنده هر دو hidden units j ها مستقل اند هر دو hidden units i ها مستقل اند.

لکن امر استقلال stochastic در توزیع راسته باستثیره در مکاف باندیشید مثال اگر v_i مدلکی داشته باشد باز هم v_i در توزیع احتمالی وجود دارد در مکاف v_i استقلال نیه نمی‌شود فقط مسیر observed اگر دامنیکی داشتیم دو متغیر داشتیم اند، در مکافی که در این مسیر مدلک است یعنی از دنیاها صفر باشد آن دو متغیر هستند بدوی یاز یعنی مثل نوچی در این مسیر.

$$P(H|V) = \frac{P(V, H)}{P(V)} = \frac{P(V, H)}{\sum_H P(V, H)} = \frac{\exp(\sum_i \alpha_i h_i + \sum_j b_j V_j + \sum_{i,j} w_{ij} h_i V_j)}{\sum_H \exp(\sum_i \alpha_i h_i + \sum_j b_j V_j + \sum_{i,j} w_{ij} h_i V_j)}$$

این در صورت تمام عبارت ها مفروض وجود دارد ثابت است.

$$\Rightarrow P(H|V) = \frac{\exp(\sum_i \alpha_i h_i + \sum_{i,j} w_{ij} h_i V_j)}{\sum_H \exp(\sum_i \alpha_i h_i + \sum_{i,j} w_{ij} h_i V_j)} = \frac{\prod_i \exp(\alpha_i h_i + h_i (\sum_j w_{ij} V_j))}{\sum_H \prod_i \exp(\alpha_i h_i + h_i (\sum_j w_{ij} V_j))}$$

تمام حالات / صورت

کل حالات عبارت ها

$$\Rightarrow P(H|V) = \frac{\prod_i \exp(\alpha_i h_i + h_i (\sum_j w_{ij} V_j))}{\prod_i (1 + \exp(\alpha_i + (\sum_j w_{ij} V_j)))}$$

$$\prod_i (1 + \exp(\alpha_i + (\sum_j w_{ij} V_j)))$$

$$\Rightarrow P(H|V) = \prod_i \frac{\exp(\alpha_i h_i + h_i (\sum_j w_{ij} V_j))}{1 + \exp(\alpha_i + (\sum_j w_{ij} V_j))}$$

$$P(H_i|V) = \prod_i P(H_i|V)$$

مجموعی درست

$$P(H_i=1|V) = \sigma(\alpha_i + \sum_j w_{ij} V_j) \quad P(H_i=0|V) = \frac{\exp(\alpha_i + \sum_j w_{ij} V_j)}{1 + \exp(\alpha_i + \sum_j w_{ij} V_j)}$$

ب) مودانسی نه V, H متعارف اند، مبنی کل مال تمام H حابه تمام V و مدل اند، تمام V های تمام H مادصل اند، متساوی این با نویش روابط بدست می آید:

$$P(V|H) = \prod_i P(V_i|H), \quad P(V_i=1|H) = \sigma(b_j + \sum_i w_{ij} h_i)$$

$$\Rightarrow \begin{cases} P(H|V) = \prod_i \prod_j \sigma(\alpha_j + \sum_i w_{ij} h_i)^{h_j} (1 - \sigma(\alpha_j + \sum_i w_{ij} h_i))^{1-h_j} \\ P(V|H) = \prod_i \sigma(b_j + \sum_i w_{ij} h_i)^{V_j} (1 - \sigma(b_j + \sum_i w_{ij} h_i))^{1-V_j} \end{cases}$$

باعث افرایش تفسیر نیز مدل می‌سود **جراحت** اهمیت هر component مدل را محترمانه توضیح دهد. خلی از مدل هار جدید مثل شبکه هار عمیق با درست هار سنتی machine learning

قابل تفسیر نیستند و بدل برای دلیل تأثیر در لایه components می‌توانیم مدل را پیکار بدل آن لایه با **الی** کرد.

حالا **این** اصلی این است که ساختار **DNN** (شبکه عصبی عمیق) را با **SCM** مدل تأثیر

روی خروجی با سفیر **causal reasoning** **component** ها / **causal effect** را توسط **what-if** برای تأثیر هر component در داده **causal structure** را قادر می‌کند که سوال های **چنین** که **چنین** خروجی با سفیر

جهت دلایل ارتباط بین این نواده ها را نشان می‌دهد، **SCM** هر لایه این امکان را می‌دهد تا

در شبکه را بفهمید و مدل را بعثت تفسیر **Causality** کنند.

میانگین **SCM** مارا قادر می‌کند **ACE** (Average causal effect) را حساب کنند برای خروجی نواده ها،

فیلتر، لایه دخیلی. برای مدل متعدد مخصوصی بین نواده بدهیم، می‌توانیم تغییرات خروجی میانگین بسیار کمتر را با توجه به این تغییر حساب کنند.

SCM به این امکان را می‌دهد که **counterfactual analysis** انجام دهیم با سرسر مطالبات فرضی که مثلاً آن فلک معناد را به قرار نواد بدهیم چه اتفاقی می‌افتد.

مدل هار بجهیز **DNN** را با **abstraction**، **conditio**n و **latent feature** توسعه مدل را تفسیر کنند.

با توجه به این **causal concept**، فیلتر هایی که برای انسان قابل فحیر لندند،

می‌توانند بعثت می‌توانند مدل را بفهمید و تفسیر کنند.

به این **SCM** تفسیر نیز **DNN** ها را به **formalize** افرایش می‌دهد.

$$A_{ji} = P(Z_{n+1}=i | Z_n=j)$$

طبق اسلامیها دامنیزه

$$\pi_i = P(Z_1=i)$$

x ها، Z ها بترتیب متغیرهای

$$\phi_{ik} = P(X_{n+1}=k | Z_n=i)$$

unobserved, observed هستند.

حالات ممکن λ کام X های ملکور است رامی نویسید:

E-step: Use x and current θ^t to calculate $P(z|x, \theta^t)$

$$M\text{-step: } \theta^{t+1} = \underset{\theta}{\operatorname{argmax}} E_{z|x} P(z|x, \theta^t) \left[\log P(x, z|\theta) \right]$$

حالات ممکن $P(x, z|\theta)$ را ممکن سینه می‌کنند، درست است

$$P(x, z|\theta) = P(z|\pi) \prod_{n=1}^N P(z_n|z_{n-1}, A) \prod_{n=1}^N P(x_n|z_n, \phi)$$

$$P(z_1|\pi_k) = \begin{cases} 0 & \text{if } z_1 \neq k \\ \pi_k & \text{else} \end{cases} \rightarrow P(z_1|\pi) = \prod_{k=1}^K \pi_k \mathbb{I}(z_1=k)$$

برابر (1) درست است زیرا از Z ها ایست، احتمال $i \in \{1, \dots, K\}$ هر کدام از π_i می‌تواند باشد
توزیع احتمال آن به صورت بالا ایست.

$$P(z_n|z_{n-1}, A) \rightarrow P(z_{n-k}|z_{n-1}=j, A) = \begin{cases} 0 & \text{if } z_n \neq k \text{ or } z_{n-1} \neq j \\ A_{jk} & \text{else} \end{cases}$$

~~هر کدام از $j \in \{1, \dots, K\}$ دارد~~ A_{jk} z_n در $\{1, \dots, K\}$ می‌تواند باشد، z_{n-1} هر چیز مگر j احتمال باشد
باشد \rightarrow توزیع احتمال آن به صورت زیر ایست:

$$P(z_n|z_{n-1}, A) = \prod_{k=1}^K \prod_{j=1}^K A_{jk} \mathbb{I}(z_n=k) \mathbb{I}(z_{n-1}=j)$$

محض حالات پرنزی که می‌توانسته باشند $\theta^n (1-\theta)^{1-n}$ را تفسیر می‌دانیم

$$P(x_n|z_n, \phi) = P(x_n=k|z_n=i, \phi) = \begin{cases} 0 & \text{if } z_n \neq i \\ P(x_n=k|\phi) & \text{else} \end{cases} \rightarrow P(x_n|\phi_k)$$

$$P(x_n|z_n, \phi) = \prod_{k=1}^K P(x_n|\phi_k)^{1(z_{n=k})}$$

حالا بدل سهت آردن توزیع داریم $P(x_n|z_n, \phi)$

$P(x, z|\theta)$ کاربردی است

$$\begin{aligned} \log P(x, z|\theta) &= \sum_{k=1}^K \mathbb{1}(z_1=k) \log \pi_k + \sum_{n=1}^N \sum_{j=1}^K \sum_{k=1}^K \underbrace{\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k)}_{\mathbb{1}(z_{n-1}=j, z_n=k)} \underbrace{\log A_{jk}}_{A_{jk}} \\ &\quad + \sum_{n=1}^N \sum_{k=1}^K \mathbb{1}(z_n=k) \log P(x_n|\phi_k) \end{aligned}$$

Expected $\leftarrow z \sim P(z|\theta, x)$ حالا روی

$$\begin{aligned} E(\log P(x, z|\theta)) &= \sum_{k=1}^K E(\mathbb{1}(z_1=k)) \log \pi_k + \sum_{n=1}^N \sum_{j=1}^K \sum_{k=1}^K E(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k)) \underbrace{\log A_{jk}}_{\log A_{jk}} \\ &\quad + \sum_{n=1}^N \sum_{k=1}^K E(\mathbb{1}(z_n=k)) \log P(x_n|\phi_k) \end{aligned}$$

حالا تعیین می کنیم: $\xi(z_{n-1}, z_n) = P(z_n, z_{n-1}|x, \theta)$, $\gamma(z_n) = P(z_n|x, \theta)$

$\mathbb{1}(z_1=k), \mathbb{1}(z_{n-1}=j), \mathbb{1}(z_n=k)$ از آنها باست

$P(z=1)$ هر متغیر باشند مطابقت باشد Expected

$$E(\mathbb{1}(z_n=k)) = \gamma(\mathbb{1}(z_n=1))$$

$$E(\mathbb{1}(z_n=k) \mathbb{1}(z_{n-1}=j)) = \xi(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k))$$

$$\begin{aligned} \rightarrow & \sum_{k=1}^K \gamma(\mathbb{1}(z_1=k)) \log \pi_k + \sum_{n=1}^N \sum_{j=1}^K \sum_{k=1}^K \xi(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k)) \log A_{jk} + \\ & \sum_{n=1}^N \sum_{k=1}^K \gamma(\mathbb{1}(z_n=k)) \log P(x_n|\phi_k) \end{aligned}$$

حالا بدل مسئله لگاریتمی کردن و سپه A_{ij} قید داشت که $\sum_k A_{jk} = 1$ باشد
از تابع ضرایب لامکنز استفاده می‌کنیم:

$$L = \sum_{n=1}^N \sum_{j=1}^K \sum_{k=1}^K \mathbb{E}(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k)) \log A_{jk} + \sum_{j=1}^K \lambda_j (1 - \sum_{k=1}^K A_{jk})$$

$$\frac{\partial L}{\partial A_{jk}} = \frac{\mathbb{E}(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k))}{A_{jk}} - \lambda_j = 0 \implies A_{jk} = \frac{\mathbb{E}(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k))}{\lambda_j},$$

$$\sum_{k=1}^K A_{jk} = \sum_{k=1}^K \frac{\mathbb{E}(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k))}{\lambda_j} = 1 \rightarrow \hat{A}_{ik} = \frac{\mathbb{E}(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k))}{\sum_{l=1}^K \mathbb{E}(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=l))},$$

$$\lambda_j = \sum_{k=1}^K \mathbb{E}(\mathbb{1}(z_{n-1}=j) \mathbb{1}(z_n=k))$$

مطابق با این نتیجه روابط رامی توسمیم، خواهیم داشت

$$\pi_k = \frac{\gamma(\mathbb{1}(z_i=k))}{\sum_{j=1}^K \gamma(\mathbb{1}(z_i=j))}, \quad \phi_{ik} = \frac{\sum_{n=1}^N \gamma(\mathbb{1}(z_n=k) \mathbb{1}(x_n=i))}{\sum_{n=1}^N \gamma(\mathbb{1}(z_n=k))}$$

بر طبق این نتیجه محاسبات آنچه رامی آورده است

استفاده می کنند تا این بحث را مسوند دار بروز ممکن است مثل صفر شود یعنی از امثال ها باشند
تعادل کنید دیتا جلوگیری مسوند حالا داریم Laplace smoothing اول

$$P(\text{work-related}) = \frac{r}{F}, P(\text{not-work-related}) = \frac{1}{F}$$

$$P(\text{schedule} | \text{work-related}) = \frac{r+1}{r+4} = \frac{r}{11}, P(\text{schedule} | \text{not-work-related}) = \frac{1+1}{r+4} = \frac{1}{9}$$

$$P(\text{event} | \text{work-related}) = \frac{r+1}{r+4} = \frac{r}{11}, P(\text{event} | \text{not-work-related}) = \frac{0+1}{r+4} = \frac{1}{9}$$

$$P(\text{meeting} | \text{work-related}) = \frac{1+1}{r+4} = \frac{1}{11}, P(\text{meeting} | \text{not-work-related}) = \frac{0+1}{r+4} = \frac{1}{9}$$

$$P(\text{deadline} | \text{work-related}) = \frac{1+1}{r+4} = \frac{1}{11}, P(\text{deadline} | \text{not-work-related}) = \frac{0+1}{r+4} = \frac{1}{9}$$

$$P(\text{movie} | \text{work-related}) = \frac{0+1}{r+4} = \frac{1}{11}, P(\text{movie} | \text{not-work-related}) = \frac{1+1}{r+4} = \frac{1}{9}$$

$$P(\text{lunch} | \text{work-related}) = \frac{0+1}{r+4} = \frac{1}{11}, P(\text{lunch} | \text{not-work-related}) = \frac{1+1}{r+4} = \frac{1}{9}$$

حالا بحسب این احتمالات احتمالات این اتفاقات را بدستور این احتمالات محاسبه کنیم

$$P(\text{work-related} | \text{email}) = \frac{P(\text{email} | \text{work-related}) P(\text{work-related})}{P(\text{email})}$$

$$P(\text{not-work-related} | \text{email}) = \frac{P(\text{email} | \text{not-work-related}) P(\text{not-work-related})}{P(\text{email})}$$

در مردم می توانیم این احتمالات را با هر مقامی محاسبه کنیم

$$P(\text{work-related} | \text{email}) = P(\text{work-related}) P(\text{schedule} | \text{work-related})^r P(\text{movie} | \text{work-related}) \\ P(\text{lunch} | \text{work-related}) / P(\text{email})$$

$$\Rightarrow P(\text{email} | \text{work-related}) = \frac{r}{F} \times \frac{1}{11} \times \frac{1}{11} / P(\text{email})$$

$$P(\text{not-work-related} | \text{email}) = P(\text{not-work-related}) P(\text{schedule} | \text{not-work-related})^r P(\text{movie} | \text{not-work-related}) \\ P(\text{lunch} | \text{not-work-related}) / P(\text{email})$$

$$\Rightarrow P(\text{not-work-related} | \text{email}) = \frac{1}{F} \times \left(\frac{1}{9}\right)^r \times \frac{1}{9} \times \frac{1}{9} / P(\text{email})$$

$P(\text{work-related} | \text{email}) < P(\text{work-related} | \text{not email})$ \Leftarrow با توجه به متادیر برسی آمده،

این با احتمال خوبی ایمیل داده شده مربوط به کار است.

نتایج $P(\text{X} | \text{y})$ را مدل ^{bayer} native, discriminative و naive تصور می‌کنیم و می‌بینیم با استفاده از تابع $\text{B}(x)$ را بدلست می‌آوریم و فرض می‌کنیم که میان فیچرها استقلال داریم در مدل $P(\text{X} | \text{y})$ مستقر $\text{P}(\text{X} | \text{y})$ را مدل می‌کنیم و دعوی می‌کنیم $\text{P}(\text{X} | \text{y}) = \frac{1}{1 + e^{-\beta_0 - \beta_1 \text{X}_1 - \dots - \beta_n \text{X}_n}}$ هست که کلاس ها را جدا کند. مثل regression , svm و $\text{logistic regression}$ معمولاً این مدلها بمحض عمل می‌کنند، زیرا استقلال میان فیچرها را فرض نمی‌کنند و مدل قبضت بسیار خواهد داشت. (فیچرها $\text{X}_1, \dots, \text{X}_n$ مستقل نیستند میان میان فیچرها) می‌گذرد بار همچنان Naive Bayes بشرط عمل می‌کنند.

$$q(x|x^s) = \text{EXP}(x|\lambda = x^s + 1)$$

$$E(q) = \frac{1}{\lambda} \longrightarrow E(q) = 0/\infty$$

(٣) از آنچه $\lambda = x^s + 1$ است $\leftarrow q = \text{EXP}(2)$

لگنه شده نمونه سمبول برداری مسدود برابر است با میانگین توزیع $\leftarrow x^p$ که عالم نمونه سمبول کسری مسدود است، برابر است.

$\alpha = \frac{\tilde{P}(x^p)}{\tilde{P}(x^s)}$ (ب) طبق نمودار احتمال دو نتاط x^s, x^p برابر است $\leftarrow \alpha = 1$ است.

(٤) از آنچه q بی توزیع منابعی بود، دربرگزید.

$$q(x^s|x^p) = \text{EXP}(x^s|\lambda = 1+x^p) = \exp(1|\lambda = 1/\alpha) = 1/\alpha e^{-1/\alpha}$$

$$q(x^p|x^s) = \text{EXP}(x^p|\lambda = 1+x^s) = \exp(0/\alpha|\lambda = 1) = 1 e^{-1/\alpha} = 1 e^{-1}$$

$$\Rightarrow \frac{q(x^s|x^p)}{q(x^p|x^s)} = \frac{1/\alpha e^{-1/\alpha}}{1 e^{-1}} = \frac{1}{\alpha} e^{-1/\alpha} \rightarrow \text{Hastings correlation} < 1$$

$$\alpha_2 = \frac{\tilde{P}(x^p) q(x^s|x^p)}{\tilde{P}(x^s) q(x^p|x^s)}, \alpha_1 = 1 \quad (\text{c})$$

$$\alpha_2 = \frac{\tilde{P}(x^p)}{\tilde{P}(x^s)} \times \frac{q(x^s|x^p)}{q(x^p|x^s)}$$

α_1 Hastings correlation

$$\Rightarrow \alpha_2 < \alpha_1$$

با عثت کو جمله سهل القامی مسدود \leftarrow در الگوریتم Hastings proposed more over \leftarrow به احتمال کمتر از α_1 باعث می شود این باعث می شود برجایی با احتمال کمتر در $(x^p|\tilde{P}_0)$ (پس کسری) حاصله باشیم تا بروزد به آنها. جزوی میانگله کارانه تر عمل می کند با وجود $\text{Hastings correlation}$ و به نتیجه با احتمال α_2 کمتر می برد.

$$p(\mu, \tau | x) = \frac{p(\mu, \tau, x)}{p(x)}, \quad p(\mu, \tau, x) = p(x|\mu, \tau) p(\mu|\tau) p(\tau)$$

↑

$$\rightarrow q(\mu, \tau) = q(\mu) q(\tau)$$

$$\rightarrow \ln q(\mu) = E_{q(\tau)} [\ln q(\mu, \tau)] = E_{q(\tau)} \left[\ln \frac{p(\mu, \tau, x)}{p(x)} \right]$$

$$= E_{q(\tau)} [\ln(p(\mu, \tau, x))] - \underbrace{E_{q(\tau)} [\ln p(x)]}_{\text{constant}}$$

~~constant~~

$$\Rightarrow \ln q(\mu) \propto E_{q(\tau)} [\ln p(x|\mu, \tau) + \ln p(\mu|\tau) + \ln p(\tau)]$$

$$\ln p(x|\mu, \tau) = \sum_{i=1}^{i.i. N} \ln \left(\frac{\sqrt{\tau}}{\sqrt{\tau_0}} \exp \left(-\frac{\tau}{\tau} (x_i - \mu)^2 \right) \right) = \frac{N}{\tau} \ln \tau - \frac{\tau}{\tau} \sum_{i=1}^N (x_i - \mu)^2 - \frac{N}{\tau} \ln (\tau)$$

$$\ln p(\mu|\tau) = \ln \left(\frac{\sqrt{\tau \cdot \tau_0}}{\sqrt{\tau_0}} \exp \left(-\frac{\tau \cdot \tau_0}{\tau} (\mu - \mu_0)^2 \right) \right) = \frac{1}{\tau} \ln (\tau \cdot \tau_0) - \frac{\tau \cdot \tau_0}{\tau} (\mu - \mu_0)^2 - \frac{1}{\tau} \ln (\tau_0)$$

$$\Rightarrow \ln q(\mu) = E_{q(\tau)} \left[\frac{N}{\tau} \ln \tau - \frac{\tau}{\tau} \sum_{i=1}^N (x_i - \mu)^2 + \frac{1}{\tau} \ln (\tau \cdot \tau_0) - \frac{\tau \cdot \tau_0}{\tau} (\mu - \mu_0)^2 \right] + \text{constant}$$

حال قرار می دهیم $E_{q(\tau)}[\tau] = \tilde{\tau}$

$$\Rightarrow \ln q(\mu) = -\frac{\tilde{\tau}}{\tau} \left(\sum_{i=1}^N (x_i - \mu)^2 + \tau_0 (\mu - \mu_0)^2 \right) + \text{const}$$

تغایر نسبت درجه 2 در \exp باشد

$$\rightarrow q(\mu) \sim N(\mu; \tilde{\mu}, \tilde{\sigma}^2)$$

$$\tilde{\mu} = \frac{\tilde{\tau} \left(\sum_{i=1}^N x_i + \tau_0 \mu_0 \right)}{N + \tau_0}$$

$$\tilde{\sigma}^2 = \frac{1}{\tilde{\tau} (N + \tau_0)}$$

$$\Rightarrow q(\mu) = N \left(\mu; \frac{\tilde{\tau} \left(\sum_{i=1}^N x_i + T_0 \mu_0 \right)}{N + T_0}, \frac{1}{\tilde{\tau}(N+T_0)} \right)$$

حالاً: محاسبة $q(\tau)$ ميّز طارئ، خواص دارئ.

$$\ln q(\tau) = E_{q(\mu)} \left[\ln q(\mu, \tau) \right] = E_{q(\mu)} \left[\ln \frac{p(x, \mu, \tau)}{p(x)} \right] =$$

$$E_{q(\mu)} \left[\ln p(x, \mu, \tau) \right] - \underbrace{E_{q(\mu)} \left[\ln p(x) \right]}_{\text{constant}}$$

$$\Rightarrow \ln q(\tau) \propto E_{q(\mu)} \left[\ln p(x|\mu, \tau) + \ln p(\mu|\tau) + \ln p(\tau) \right] \Rightarrow$$

$$\ln q(\tau) \propto E_{q(\mu)} \left[\frac{N}{\tau} \ln \tau - \frac{\tau}{\tau} \sum_{i=1}^N (x_i - \mu)^2 + \underbrace{\frac{1}{\tau} \ln (\tau T_0) - \frac{T_0}{\tau} (\mu - \mu_0)}_{\frac{1}{\tau} \ln \tau + \frac{1}{\tau} \ln T_0} + \cancel{\ln p(\tau)} + \cancel{\text{constant}} \right]$$

~~constant~~

$$\frac{1}{\tau} \ln \tau + \frac{1}{\tau} \ln T_0 \quad (\alpha - 1) \ln \tau - \beta \tau - \ln \Gamma(\alpha) + \alpha \ln \beta$$

$$\Rightarrow E_{q(\tau)} \propto \left(\frac{N}{\tau} + \frac{1}{\tau} \right) \ln \tau - \frac{\tau}{\tau} E_{q(\mu)} \left[\sum_{i=1}^N (x_i - \mu)^2 + T_0 (\mu - \mu_0)^2 \right] + \ln p(\tau) + \text{constant}$$

$$\Rightarrow E_{q(\tau)} \propto \left(\frac{N}{\tau} + \frac{1}{\tau} \right) \ln \tau - \frac{\tau}{\tau} \left(\sum_{i=1}^N E_{q(\mu)} [(x_i - \mu)^2] + T_0 (E_{q(\mu)} [\mu] - \mu_0)^2 \right) + \ln p(\tau)$$

$\tilde{\mu} = E_{q(\mu)} [\mu]$

مقدار محاسبة

$$\sigma_{\mu}^2 = V_{q(\mu)} (\mu)$$

$$\rightarrow E_{q(\mu)} [(x_i - \mu)^2] = (x_i - \tilde{\mu})^2 + \sigma_{\mu}^2, \quad E_{q(\mu)} [(\mu - \mu_0)^2] = (\tilde{\mu} - \mu_0)^2 + \sigma_{\mu}^2$$

$$\rightarrow E_{q(\mu)} \left[\frac{\tau}{\tau} \sum_{i=1}^N (x_i - \mu)^2 \right] = \frac{\tau}{\tau} \sum_{i=1}^N ((x_i - \tilde{\mu})^2 + \sigma_{\mu}^2)$$

$$E_{q(\mu)} \left[\frac{T_0}{\tau} (\mu - \mu_0)^2 \right] = \frac{T_0}{\tau} ((\tilde{\mu} - \mu_0)^2 + \sigma_{\mu}^2)$$

$$\Rightarrow \ln q(\tau) \propto (\alpha + \frac{N+1}{r} - 1) \ln \tau - \tau \left(\beta + \frac{1}{r} \sum_{i=1}^N ((x_i - \bar{\mu})^r + \sigma_{\mu}^r) + \frac{\tau_0}{r} ((\bar{\mu} - \mu_0)^r + \sigma_{\mu}^r) \right)$$

$$q(\tau) \propto \tau^{\alpha + \frac{N+1}{r} - 1} e^{-\tau \left(\beta + \frac{1}{r} \sum_{i=1}^N ((x_i - \bar{\mu})^r + \sigma_{\mu}^r) + \frac{\tau_0}{r} ((\bar{\mu} - \mu_0)^r + \sigma_{\mu}^r) \right)}$$

$$\rightarrow q(\tau) = \text{Gamma}(\tau, \alpha', \beta') , \quad \alpha' = \alpha + \frac{N+1}{r}$$

$$\beta' = \beta + \frac{1}{r} \sum_{i=1}^N ((x_i - \bar{\mu})^r + \sigma_{\mu}^r) + \frac{\tau_0}{r} ((\bar{\mu} - \mu_0)^r + \sigma_{\mu}^r)$$
