



## مسئله ۱. تبدیل متغیر

حل.

الف) از آنجایی که  $Z_1$  و  $Z_2$  از توزیع نرمال هستند و مستقل اند (چون ماتریس cov برابر است با I و در درایه ی اول و دوم Y ترکیبی با مجموع ضرایب یک و ضرایب مثبت از  $Z_1$  و  $Z_2$  داریم، پس توزیع درایه ی اول و دوم Y نیز گاوسی است، حالا باید پارامترهای توزیع گاوسی که Y از آن آمده است را بدست آوریم :

$$Z \sim \mathcal{N} \left( \begin{bmatrix} 0 \\ 0 \end{bmatrix}, I \right) \quad Y = \begin{bmatrix} \frac{3}{5}Z_1(t) + \frac{1}{5}Z_2(t) \\ \frac{1}{5}Z_1(t) + \frac{4}{5}Z_2(t) \end{bmatrix}$$

حالا اگر تبدیل خطی بنویسیم برای بدست آوردن Y از روی Z خواهیم داشت که :

$$Y = \begin{bmatrix} \frac{3}{5} & \frac{1}{5} \\ \frac{1}{5} & \frac{4}{5} \end{bmatrix} \begin{bmatrix} Z_1(t) \\ Z_2(t) \end{bmatrix}$$

ماتریس سمت چپی را A می نامیم و از طرفی داریم که:

$$\mathbb{E}(Y) = \mathbb{E}(AZ) = A\mathbb{E}(Z) = A \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\Sigma_Y = \mathbb{E}((Y - \mathbb{E}(Y))(Y - \mathbb{E}(Y))^T) = \mathbb{E}((Y - \mathbb{E}(Y))(Y - \mathbb{E}(Y))^T) =$$

$$\mathbb{E}((AZ - \mathbb{E}(AZ))(AZ - \mathbb{E}(AZ))^T) = A\mathbb{E}((Z - \mathbb{E}(Z))(Z - \mathbb{E}(Z))^T)A^T =$$

$$A\Sigma_ZA^T = AA^T = \begin{bmatrix} \frac{3}{5} & \frac{1}{5} \\ \frac{1}{5} & \frac{4}{5} \end{bmatrix} \begin{bmatrix} \frac{3}{5} & \frac{1}{5} \\ \frac{1}{5} & \frac{4}{5} \end{bmatrix}^T = \begin{bmatrix} \frac{13}{25} & \frac{11}{25} \\ \frac{11}{25} & \frac{17}{25} \end{bmatrix}$$

پس خواهیم داشت که :

$$\rightarrow Y \sim \mathcal{N} \left( \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} \frac{13}{25} & \frac{11}{25} \\ \frac{11}{25} & \frac{17}{25} \end{bmatrix} \right)$$

حالا به بدست آوردن PDF توزیع این بردار می پردازیم :

$$f_Y(y) = \frac{1}{\sqrt{2\pi}^2 |\Sigma_Y|^{1/2}} \exp \left( -\frac{1}{2} (y - \mu)^T \Sigma_Y^{-1} (y - \mu) \right) =$$

$$\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad |\Sigma_Y| = \left| \begin{bmatrix} \frac{13}{25} & \frac{11}{25} \\ \frac{11}{25} & \frac{17}{25} \end{bmatrix} \right| = \frac{1}{625} \left| \begin{bmatrix} 13 & 11 \\ 11 & 17 \end{bmatrix} \right| = \frac{100}{625} = \frac{4}{25}$$

$$\rightarrow \Sigma_Y^{-1} = \frac{1}{|\Sigma_Y|} \begin{bmatrix} 17 & -11 \\ -11 & 13 \end{bmatrix}$$

$$\rightarrow f_Y(y) = \frac{1}{\sqrt{\pi} \delta} \exp \left( -\frac{1}{\sqrt{\pi}} y^T \left( \frac{25}{4} \begin{bmatrix} 17 & -11 \\ -11 & 13 \end{bmatrix} \right) y \right)$$

$$\rightarrow f_Y(y) = \frac{5}{4\pi} \exp \left( -\frac{25}{8} y^T \left( \begin{bmatrix} 17 & -11 \\ -11 & 13 \end{bmatrix} \right) y \right)$$

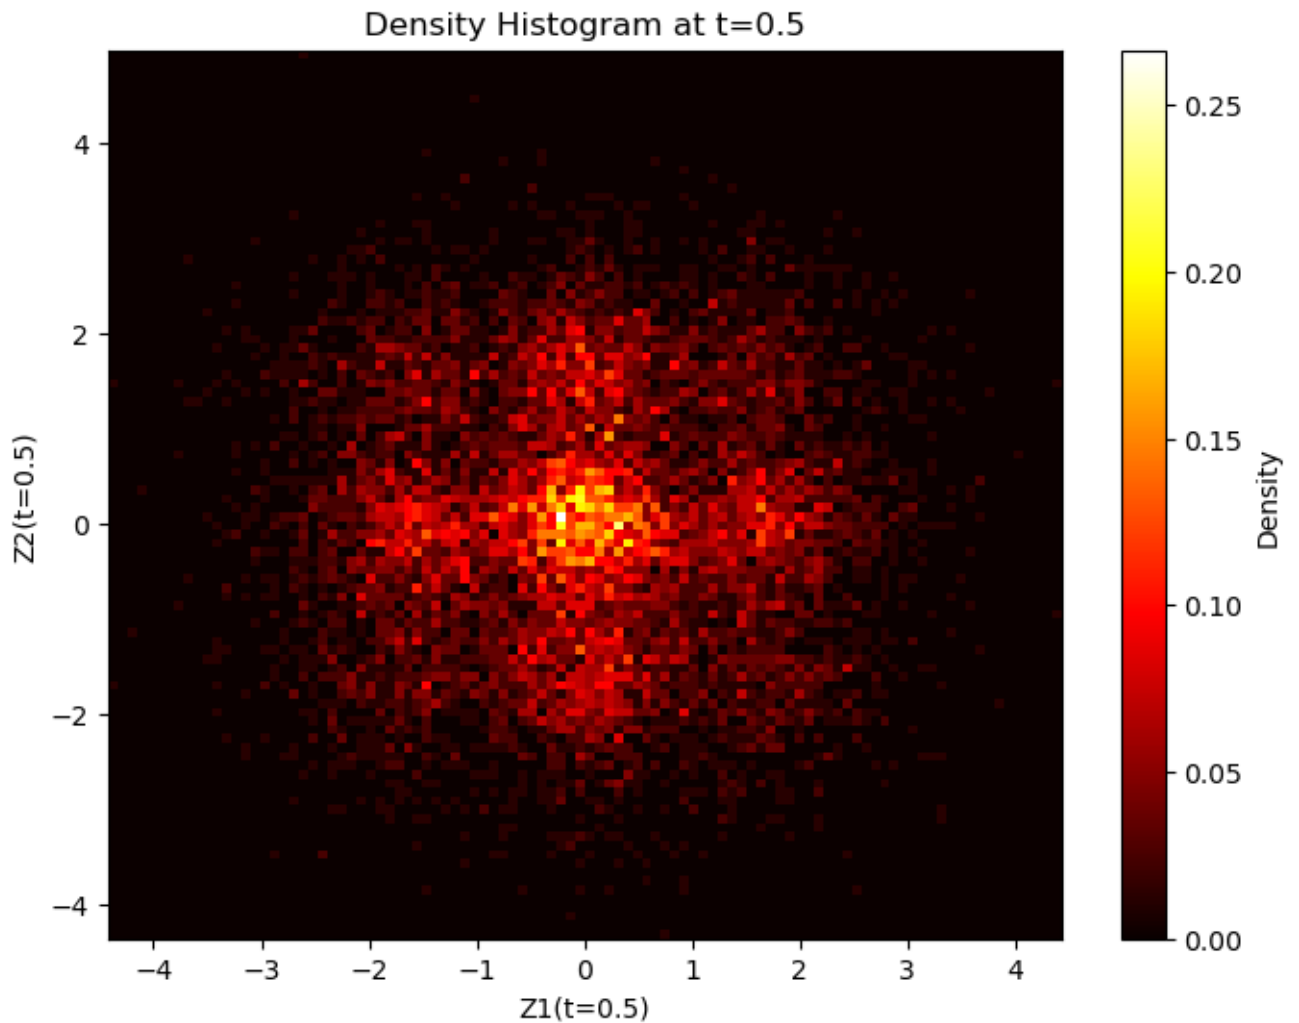
ب ۱) از معادله ها داریم که :

$$Z(t+1) = Z(t) + \frac{dZ}{dt} dt \rightarrow \begin{bmatrix} Z_1(t+1) \\ Z_2(t+1) \end{bmatrix} = \begin{bmatrix} Z_1(t) \\ Z_2(t) \end{bmatrix} + \frac{d}{dt} \begin{bmatrix} Z_1(t) \\ Z_2(t) \end{bmatrix} dt =$$

$$\begin{bmatrix} Z_1(t) \\ Z_2(t) \end{bmatrix} + \begin{bmatrix} \frac{Z_1(t)}{\frac{dt}{dt}} \\ \frac{Z_2(t)}{\frac{dt}{dt}} \end{bmatrix} dt = \begin{bmatrix} Z_1(t) \\ Z_2(t) \end{bmatrix} + \begin{bmatrix} \tanh(Z_1(t)^3) \\ \tanh(Z_2(t)^3) \end{bmatrix} dt$$

$$\rightarrow Z(t+1) = Z(t) + \tanh(Z(t)) dt$$

حالا با استفاده از python هیستوگرام مربوط را در  $t = 0.5$  می کشیم، خواهیم داشت که :



ب ۲) طبق قضیه ی داده شده در مقاله داریم که :

$$\frac{\partial \log p(z(t))}{\partial t} = -tr \left( \frac{df}{dz(t)} \right)$$

همچنین داریم که  $f(z(t))$  برابر است با  $\frac{dz}{dt}$  ، پس خواهیم داشت که :

$$f(Z(t)) = \begin{bmatrix} \tanh(Z_1(t)^{\mathfrak{r}}) \\ \tanh(Z_2(t)^{\mathfrak{r}}) \end{bmatrix}$$

$$\frac{df}{dZ(t)} = \begin{bmatrix} \frac{d \tanh(Z_1(t)^{\mathfrak{r}})}{d Z_1(t)} & \cdot \\ \cdot & \frac{d \tanh(Z_2(t)^{\mathfrak{r}})}{d Z_2(t)} \end{bmatrix} =$$

$$\begin{bmatrix} \mathfrak{r} Z_1(t)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_1(t)^{\mathfrak{r}})) & \cdot \\ \cdot & \mathfrak{r} Z_2(t)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_2(t)^{\mathfrak{r}})) \end{bmatrix}$$

اسم این ماتریس را  $J$  می گذاریم خواهیم داشت که :

$$tr(J) = \mathfrak{r} Z_1(t)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_1(t)^{\mathfrak{r}})) + \mathfrak{r} Z_2(t)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_2(t)^{\mathfrak{r}}))$$

$$\frac{\partial \log p(Z(t))}{\partial t} = -tr(J) = -(\mathfrak{r} Z_1(t)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_1(t)^{\mathfrak{r}})) + \mathfrak{r} Z_2(t)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_2(t)^{\mathfrak{r}})))$$

حالا از طرفی داریم که :

$$\frac{\partial \log p(Z(t))}{\partial t} = \frac{\frac{\partial p(Z(t))}{\partial t}}{p(Z(t))} \longrightarrow$$


$$\frac{\frac{\partial p(Z(t))}{\partial t}}{p(Z(t))} = -tr(J) \longrightarrow \frac{\partial p(Z(t))}{\partial t} = -tr(J)p(Z(t)) \longrightarrow$$

$$\frac{\partial p(Z(t))}{\partial t} = -p(Z(t))(\mathfrak{r} Z_1(t)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_1(t)^{\mathfrak{r}})) + \mathfrak{r} Z_2(t)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_2(t)^{\mathfrak{r}})))$$

ب ۳) حالا با حل این معادله ی دیفرانسیل خواهیم داشت که :

$$p(Z(t)) = p(Z(\cdot)) \exp \left( - \int_{\cdot}^t (\mathfrak{r} Z_1(s)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_1(s)^{\mathfrak{r}})) + \mathfrak{r} Z_2(s)^{\mathfrak{r}} (1 - \tanh^{\mathfrak{r}}(Z_2(s)^{\mathfrak{r}}))) ds \right)$$

حالا نمودار آنرا می کشیم، خواهیم داشت که :



ب ۴) به این روش Sensitivity Adjoint نیز می‌گویند به این صورت مشتق را حساب می‌کند که ابتدا معادله‌ی دیفرانسیل را از  $t=0$  تا  $t=T$  حل می‌کنیم و  $Z(T)$  را بدست می‌آوریم سپس متغیر Adjoint را به این صورت تعریف می‌کنیم که :

$$a(t) = \frac{\partial L}{\partial z(t)}$$

این متغیر به ما کمک می‌کند تا گرادیان را در زمان  $t$  محاسبه کنیم. با استفاده از  $a(T)$  (گرادیان در زمان نهایی،  $T$ ) معادله‌ی Adjoint زیر را به صورت معکوس از  $t=T$  به  $t=0$  حل می‌کنیم :

$$-a(t)^T \frac{\partial f}{\partial z}$$

محاسبه‌ی گرادیان نسبت به پارامتر  $\theta$  نیاز به محاسبه‌ی انتگرال زیر دارد :

$$\frac{dL}{d\theta} = - \int_{t_1}^{t_2} \frac{\partial f(z(t), t, \theta)}{\partial \theta} dt$$

در اینجا مسئله هم اینگونه داریم که :

$$L(\theta) = \mathbb{E}_{x \sim Data} [\log p(x; \theta)], \quad f(Z(t), t, \theta) = \frac{dZ(t)}{dt}$$

پس با وجود اینها در روش بالا جایگذاری می‌کنیم و گرادیان را محاسبه می‌کنیم.

ب ۵) عدم دقت کافی در تقریب‌های عددی: روش‌های عددی مانند اویلر معمولاً برای تقریب راه‌حل معادلات دیفرانسیل استفاده می‌شوند و دقت محدودی دارند. مشتق‌گیری مستقیم از این تقریب‌های عددی خطاهای موجود را تقویت می‌کند و به نتایج ناپایداری منجر می‌شود.

مشکلات ناشی از ناپیوستگی و نویز عددی: روش‌های عددی معمولاً بر پایه گسسته‌سازی کار می‌کنند، و مقادیر به دست آمده از آنها ممکن است شامل ناپیوستگی یا نویز باشند. مشتق‌گیری از این مقادیر باعث تقویت نویز عددی و

ایجاد نتایج غیرواقعی یا ناپایدار می‌شود. عدم تعمیم‌پذیری به فضاهای پیچیده‌تر: روش‌هایی مثل اویلر برای مدل‌سازی در فضای زمان گسسته طراحی شده‌اند. مشتق‌گیری مستقیم از این روش‌ها ممکن است در فضاهای پارامتری یا شبکه‌های پیچیده‌تری که نیازمند مشتق‌های دقیق‌تر هستند، ناکارآمد باشد.

کارایی کمتر در زمینه‌های بهینه‌سازی: در زمینه‌هایی مانند یادگیری ماشین و بهینه‌سازی، محاسبه گرادیان‌ها باید دقیق و قابل اعتماد باشد. استفاده از روش‌های عددی به جای روش‌های تحلیلی (یا روش‌های مناسب‌تر مثل AutoDiff) ممکن است منجر به کندی و خطاهای غیرقابل قبول در فرآیند بهینه‌سازی شود.

▷

## مسئله‌ی ۲. مدل انرژی

حل.

الف) می‌دانیم که داریم :

$$p_{\phi}(x) \propto e^{-E_{\phi}(x)}, \quad Z_{\phi} = \int e^{-E_{\phi}(x)} dx$$

یا به عبارتی داریم که :

$$p_{\phi}(x) = \frac{e^{-E_{\phi}(x)}}{Z_{\phi}}$$

پس داریم که :

$$\log p_{\phi}(x) = \log e^{-E_{\phi}(x)} - \log Z_{\phi} = -E_{\phi}(x) - \log Z_{\phi}$$

پس خواهیم داشت که :

$$\nabla_{\phi} \log p_{\phi}(x) = -\nabla_{\phi} E_{\phi}(x) - \nabla_{\phi} \log Z_{\phi}$$

حالا داریم که :

$$\nabla_{\phi} \log Z_{\phi} = \frac{\nabla_{\phi} Z_{\phi}}{Z_{\phi}} = \frac{\nabla_{\phi} \int e^{-E_{\phi}(x)} dx}{Z_{\phi}} = \frac{\int \nabla_{\phi} e^{-E_{\phi}(x)} dx}{Z_{\phi}} =$$

$$-\frac{\int e^{-E_{\phi}(x)} \nabla_{\phi} E_{\phi}(x) dx}{Z_{\phi}} = -\int \frac{e^{-E_{\phi}(x)}}{Z_{\phi}} \nabla_{\phi} E_{\phi}(x) dx =$$

$$-\int p_{\phi}(x) \nabla_{\phi} E_{\phi}(x) dx = \int p_{\phi}(x) (-\nabla_{\phi} E_{\phi}(x)) dx =$$

$$\mathbb{E}_{x \sim p_{\phi}(x)} [-\nabla_{\phi} E_{\phi}(x)]$$

در نتیجه حکم ثابت می‌شود.

ب) برای سمپل‌گیری از  $p_{\phi}(x)$  نیاز داریم تا  $Z_{\phi}$  را محاسبه کنیم که پیچیدگی محاسباتی بالایی دارد زیرا باید روی کل فضای داده انتگرال بگیریم و به همین خاطر سمپل‌گیری از این توزیع بسیار دشوار است.

▷